

Ch 05. EM 알고리즘

1. KL 발산

2. EM 알고리즘 도출 ①

3. EM 알고리즘 도출 ②

4. GMM과 EM 알고리즘

5. EM 알고리즘 구현



5.1 KL 발산

우선 표기법을 변경!

$E_{p(x)}[f(x)] = \int f(x)p(x) dx \Rightarrow$ 연속 확률 변수 x 가 있고 그 확률밀도가 $p(x)$ 일때,
함수 $f(x)$ 의 기댓값을 의미!


KL 발산 (클백-라이블러 발산, Kullback-Leibler divergence) 란?!?!
 \Rightarrow 두 확률 분포의 차이! 를 측정하는 척도!

$\Rightarrow D_{KL}(p||q) = \int p(x) \log \frac{p(x)}{q(x)} dx$ 또는! $\sum_x p(x) \log \frac{p(x)}{q(x)}$

KL 발산의 특징은?

1. 두 확률분포가 다들수록 값이 커진다!
2. 두 확률분포가 같으면 0이다!
3. 같지 않으면 0보다 크다!
4. $D_{KL}(p||q)$ 와 $D_{KL}(q||p)$ 는 다르다!

KL 발산과 최대 가능도 추론의 관계



$p_*(x) \xrightarrow{\text{샘플링}} \{x^{(1)}, x^{(2)}, \dots, x^{(N)}\} \Rightarrow$ 이걸로 $p_\theta(x)$ 최대가능도!

즉! $\log \prod_{n=1}^N p_\theta(x^{(n)}) = \sum_{n=1}^N \log p_\theta(x^{(n)})$
 $\Rightarrow \hat{\theta} = \arg \max_{\theta} \sum_{n=1}^N \log p_\theta(x^{(n)})$

행실 아이디어는?

$p_\theta(x)$ 를 $p_*(x)$ 에 최대한 가깝게 만든다



$p_*(x)$ 와 $p_\theta(x)$ 의 KL 발산을 최소화한다

즉! $D_{KL}(p_*||p_\theta) = \int p_*(x) \log \frac{p_*(x)}{p_\theta(x)} dx$ 를 계산!

그러나! $p_*(x)$ 를 정확하게 몰라...

따라서! 몬테카를로 방법 (Monte Carlo method) 을 사용

몬테카를로 방법론?

- ⇒ 확률분포와 기대값의 근사값을 구하는 방법!
- ⇒ 무작위 샘플 기반의 결과값의 평균을 구해서 근사!
- ⇒ 근사 방법론!

1. $P_*(x)$ 에 따라 샘플 $\{x^{(1)}, x^{(2)}, \dots, x^{(N)}\}$ 를 생성!
2. 각 데이터 $x^{(i)}$ 에서 $f(x^{(i)})$ 를 구해서 평균을 구한다

2.7! $E_{P_*(x)}[f(x)] = \int P_*(x) f(x) dx$

$\approx \frac{1}{N} \sum_{n=1}^N f(x^{(n)}) \quad (x^{(n)} \sim P_*(x))$

몬테카를로를 KL발산에 적용하면?

$D_{KL}(P_* || P_\theta) = \int P_*(x) \log \frac{P_*(x)}{P_\theta(x)} dx$

$\approx \frac{1}{N} \sum_{n=1}^N \log \frac{P_*(x^{(n)})}{P_\theta(x^{(n)})} \quad (x^{(n)} \sim P_*(x))$

$= \frac{1}{N} \sum_{n=1}^N (\log P_*(x^{(n)}) - \log P_\theta(x^{(n)}))$

여기서! 가장 작은 KL!

$\rightarrow \arg \min_{\theta} D_K(P_* || P_\theta)$

$\approx \arg \min_{\theta} \left(-\frac{1}{N} \sum_{n=1}^N \log P_\theta(x^{(n)}) \right)$


$= \arg \max_{\theta} \sum_{n=1}^N \log P_\theta(x^{(n)})$

2.7! $\arg \min_{\theta} D_{KL}(P_* || P_\theta) \approx \arg \max_{\theta} \sum_{n=1}^N \log P_\theta(x_n)$

→ 최대 KL발산!

→ 최대! 최대가능!

5.2 EM 알고리즘을 조금 (1)



여러 개의 데이터 $D = \{x^{(1)}, x^{(2)}, \dots, x^{(N)}\}$ 일련의 데이터

$$\log p_{\theta}(x) = \log \sum_z p_{\theta}(x, z)$$

관찰 가능한
확률 변수
잠재변수
배경변수

$$\begin{aligned} \log p_{\theta}(D) &= \log (p_{\theta}(x^{(1)}) \cdot p_{\theta}(x^{(2)}) \cdot \dots \cdot p_{\theta}(x^{(N)})) \\ &= \sum_{n=1}^N \log p_{\theta}(x^{(n)}) \\ &= \sum_{n=1}^N \log \sum_{z^{(n)}} p_{\theta}(x^{(n)}, z^{(n)}) \end{aligned}$$

이런데 "로그-합"이라서 어려움
이를 위해, 임의의 확률 $q(z)$ 를 사용

그러면? 1단계

$$\begin{aligned} \log p_{\theta}(x) &= \log \frac{p_{\theta}(x, z)}{p_{\theta}(z|x)} \\ &= \log \frac{p_{\theta}(x, z) q(z)}{p_{\theta}(z|x) q(z)} \\ &= \log \frac{p_{\theta}(x, z)}{q(z)} + \log \frac{q(z)}{p_{\theta}(z|x)} \end{aligned}$$

아직 로그-합이야!
2단계 이걸 KL발산으로 바꿔!

그러면 2단계

$$\begin{aligned} \log p_{\theta}(x) &= \log p_{\theta}(x) \sum_z q(z) \\ &= \sum_z q(z) \log p_{\theta}(x) \\ &= \sum_z q(z) \left(\log \frac{p_{\theta}(x, z)}{q(z)} + \log \frac{q(z)}{p_{\theta}(z|x)} \right) \\ &= \sum_z q(z) \log \frac{p_{\theta}(x, z)}{q(z)} + \sum_z q(z) \log \frac{q(z)}{p_{\theta}(z|x)} \\ &= \sum_z q(z) \log \frac{p_{\theta}(x, z)}{q(z)} + D_{KL}(q(z), p_{\theta}(z|x)) \end{aligned}$$

이러면 로그-곱!

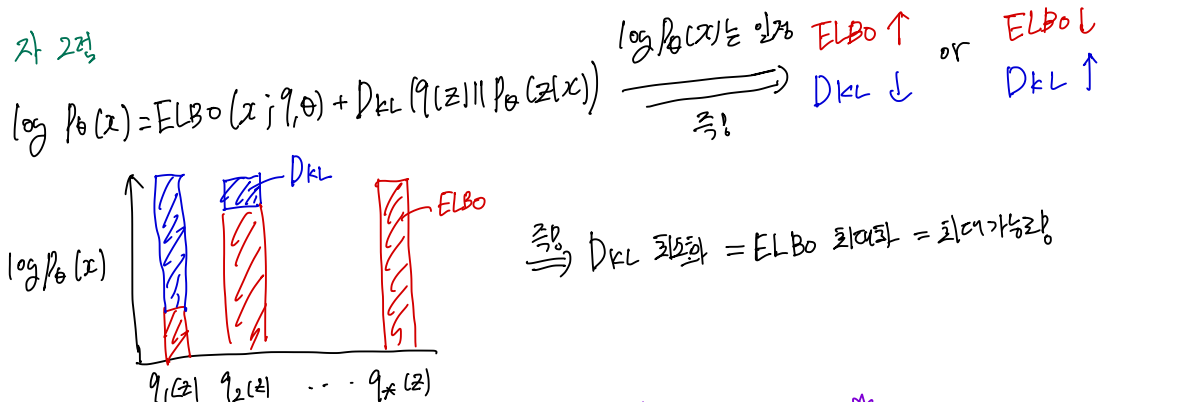
즉! 극복!

5.3 EM 알고리즘 흐름 (2)

ELBO (Evidence Lower Bound, 증거하한) 은! \rightarrow $\left\{ \begin{array}{l} \text{가만 낮은 것 가능함} \\ \text{에이.. 아무리 낮아도 이것보다 가능도가 낮잖아..} \\ \text{그러 느낌 ㅇ} \end{array} \right.$

$$\log p_{\theta}(x) = \sum_z q(z) \log \frac{p_{\theta}(x, z)}{q(z)} + \underbrace{D_{KL}(q(z) \parallel p_{\theta}(z|x))}_{\geq 0}$$

$$\geq \sum_z q(z) \log \frac{p_{\theta}(x, z)}{q(z)} \Rightarrow \text{ELBO!!!} \Rightarrow \text{ELBO}(x; q, \theta) = \sum_z q(z) \log \frac{p_{\theta}(x, z)}{q(z)}$$




2차원 $q(z)$ 최적화 $\Rightarrow \theta = \theta_{old}$ 고정 $\xRightarrow{D_{KL}=0}$ $p_{\theta_{old}}(z|x) = q(z)$

$$\hookrightarrow \text{ELBO}(x; q=p_{\theta_{old}}(z|x), \theta) = \sum_z p_{\theta_{old}}(z|x) \log \frac{p_{\theta}(x, z)}{p_{\theta_{old}}(z|x)}$$

이것이 E-단계! $\Rightarrow E = E_{p_{\theta_{old}}(z|x)} \left[\log \frac{p_{\theta}(x, z)}{p_{\theta_{old}}(z|x)} \right]$
 (Expectation calc-step)

2차원 다른 θ 최적화 $\Rightarrow \theta$ 에 대한 미분! \Rightarrow 최적 θ 발견! \Rightarrow 이것이 M-단계
 (Maximization-step)

이제 E-단계, M-단계 반복... 증!



2점 데이터가 여러 개일 때

관측 데이터 $D = \{x^{(1)}, x^{(2)}, \dots, x^{(N)}\}$, 임의 표본 분포 $q = \{q^{(1)}, q^{(2)}, \dots, q^{(N)}\}$ 일 때

2점 분포 가능도와 ELBO의 관계는?

$$\begin{aligned} \sum_{n=1}^N \log \sum_{z^{(n)}} p_{\theta}(x^{(n)}, z^{(n)}) &\geq \sum_{n=1}^N \text{ELBO}(x^{(n)}; q^{(n)}, \theta) \\ &= \sum_{n=1}^N \sum_{z^{(n)}} q^{(n)}(z^{(n)}) \log \frac{p_{\theta}(x^{(n)}, z^{(n)})}{q^{(n)}(z^{(n)})} \end{aligned}$$

EM 알고리즘은!

1. E-단계 : $\{q^{(1)}, q^{(2)}, \dots, q^{(N)}\}$ 갱신 (E 과정)

\Rightarrow 각 n 에 대해 $q^{(n)}(z) = p_{\theta}(z|x^{(n)})$ 으로 갱신

2. M-단계 : θ 갱신 ($\{q^{(1)}, q^{(2)}, \dots, q^{(N)}\}$ 고정)

$\rightarrow \sum_{n=1}^N \text{ELBO}(x^{(n)}; q^{(n)}, \theta)$ 가 최대가 되는 θ 갱신

3. 종료 : 이전 2점 가능도와 이후 2점 가능도 비교

즉! GMM에 대한 EM은?

E-단계는 각 k 에 대해

$$q^{(n)}(k) = \frac{\phi_k N(x^{(n)}; \mu_k, \Sigma_k)}{\sum_{j=1}^K \phi_j N(x^{(n)}; \mu_j, \Sigma_j)}$$

전체 GMM 중 k 파라미터 분포와 관련된 확률?!?!

중요 관점은 \rightarrow GMM로 가능도

$$\frac{1}{N} \sum_{n=1}^N \log \sum_{j=1}^K \phi_j N(x^{(n)}; \mu_j, \Sigma_j)$$

\rightarrow GMM 공식

\rightarrow GMM 표준 로그 가능도

M-단계는 각 k 에 대해

$$\phi_k = \frac{1}{N} \sum_{n=1}^N q^{(n)}(k)$$

$$\mu_k = \frac{\sum_{n=1}^N q^{(n)}(k) x^{(n)}}{\sum_{n=1}^N q^{(n)}(k)}$$

$$\Sigma_k = \frac{\sum_{n=1}^N (q^{(n)}(k) (x^{(n)} - \mu_k)(x^{(n)} - \mu_k)^T)}{\sum_{n=1}^N q^{(n)}(k)}$$

\Rightarrow 모든 데이터에 대한 계산

k 번째 파라미터 기반 = 2점

전체 데이터에 대해?!?!

이유, 가장 적절한 파라미터 선택?!?!