





## Ch 07. 변이형 오토인코더

---

1. VAE와 디코더
2. VAE와 인코더
3. ELBO 최적화
4. VAE 구현



# 7.1 VAE와 디코더



## 하나의 정규분포!

매개변수  $\theta = \{\mu, \Sigma\}$ , 데이터  $x \Rightarrow$  확률 분포  $= p_\theta(x) = \mathcal{N}(x; \theta)$  이고!

$N$ 개 관측데이터  $D = \{x^{(1)}, x^{(2)}, \dots, x^{(N)}\}$   $\xrightarrow{\text{32 가우스}}$   $\log p_\theta(D) = \log(p_\theta(x^{(1)}) p_\theta(x^{(2)}) \dots p_\theta(x^{(N)}))$

## GMM은?

1. 다양한 분포에 따라  $K$ 개의 정규분포 중 하나를 선택  $\Rightarrow$  ELBO를 복잡함수로!  $\Rightarrow$  EM 알고리즘 수행!
2. 선택한 정규분포에서 데이터를 생성


이때! ELBO는

$$\log p_\theta(D) \geq \sum_{n=1}^N \sum_{z^{(n)}} q^{(n)}(z^{(n)}) \log \frac{p_\theta(x^{(n)}, z^{(n)})}{q^{(n)}(z^{(n)})}$$

## VAE는?

VAE의 디코더 생성 과정

1. 잠재 변수  $z$ 를 **고정된 정규 분포**에서 생성!  $\} \text{증거}$
2. 신경망을 통해  $z$ 를  $x$ 로 변환!




**따라서!**  
 $\hat{x} = \text{NeuralNet}(\hat{z}; \theta)$   
 입력  $\hat{z}$   $\rightarrow$  신경망의 매개변수  $\theta$

목표: **잠재 변수  $z$ 와 확률 분포  $p_\theta(x)$ 를 일치!**  
 이를 위해 신경망  $p_\theta(z|x)$ 를 모델링!  
 ( $z \rightarrow x$ )

$p_\theta(z|x) = \mathcal{N}(x; \hat{x}, I) \Rightarrow$  **이는 손실 평균 버전 상의 정규분포를 따라!**

# VAE의 디코더의 수식 순서



2점 EM으로 할 수 있나?  $\rightarrow$  NO!

VAE에서 E-스텝  $\rightarrow q^{(m)}(z) = p_{\theta}(z|x^{(m)}) = \frac{p_{\theta}(x^{(m)}, z)}{p_{\theta}(x^{(m)})}$

$$= \frac{p_{\theta}(x^{(m)}, z)}{\int p_{\theta}(x^{(m)}, z) dz}$$

$\hookrightarrow$  GMM : 이산  $\rightarrow \sum \rightarrow$  계산량  $\downarrow$

VAE : 연속  $\rightarrow \int \rightarrow$  계산량  $\uparrow$

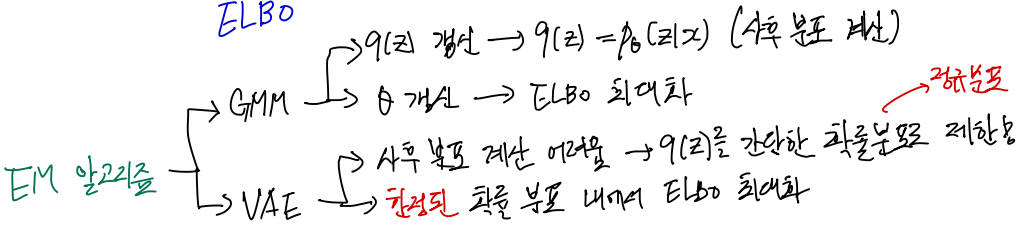
## 7.2 VAE와 인코더

EM 알고리즘!

$$\log p_{\theta}(x) = \int q(z) \log \frac{p_{\theta}(x, z)}{q(z)} dz + \underbrace{D_{KL}(q(z) \parallel p_{\theta}(z|x))}_{\text{KL분포}}$$

$$\geq \underbrace{\int q(z) \log \frac{p_{\theta}(x, z)}{q(z)} dz}_{\text{ELBO}}$$

ELBO




즉,  $q_{\psi}(z) = N(z; \mu, \Sigma) \rightarrow$  한양!

따라서  $\rightarrow \log p_{\theta}(x) = \int q_{\psi}(z) \log \frac{p_{\theta}(x, z)}{q_{\psi}(z)} dz + D_{KL}(q_{\psi}(z) \parallel p_{\theta}(z|x))$

ELBO!

ELBO 최대화  $\rightarrow ELBO(x; \theta, \psi) = \int q_{\psi}(z) \log \frac{p_{\theta}(x, z)}{q_{\psi}(z)} dz$



중요  $p_{\theta}(z|x)$ 와  $q_{\psi}(z)$ 가 같지 않아!

즉, 근사!를 해야함!

이걸 변분 근사 (variational approximation) or 라고 해!

변분 베이지 (variational bayes)

2월 전체 데이터에서는 ?! ?!

$\sum_{n=1}^N \text{ELBO}(x^{(n)}; \phi, \psi^{(n)}) = \sum_{n=1}^N \int q_{\psi^{(n)}}(z) \log \frac{p_{\phi}(x^{(n)}; z)}{q_{\psi^{(n)}}(z)} dz$


증명

$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_n \end{pmatrix}, \sigma = \begin{pmatrix} \sigma_1 \\ \sigma_2 \\ \vdots \\ \sigma_n \end{pmatrix}, z = \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{pmatrix}$

따라서 VAE 인코더가 하는 일은


$\mu, \sigma = \text{NeuralNet}(x; \phi)$   
 $q_{\psi}(z|x) = N(z; \mu, \sigma^2 I)$

공식



$x^{(n)}$ 은 ...  $N$ 개 ...  
 → 근제 이걸  $q_{\psi^{(n)}}(z)$ 가  $N$ 개 필요 ...  
 너무 많음

그래서! 신경망으로 대체!



즉! 큰 수의 샘플의 매개변수( $\psi$ )는  
 신경망으로 계산하는 방법임!

분할 상환 쿼리!  
 (amortized inference)

## 7.3 ELBO 최적화

VAE 디코더

$$p(z) = N(z; 0, I)$$

$$\hat{z} = \text{NeuralNet}(z; \theta)$$

$$p_\theta(x|z) = N(x; \hat{z}, I)$$

VAE 인코더

$$\mu, \sigma = \text{NeuralNet}(x; \phi)$$

$$q_\phi(z|x) = N(z; \mu, \sigma^2 I)$$

하나의 데이터에 대한 ELBO

$$\text{ELBO}(x; \theta, \phi) = \int q_\phi(z|x) \log \frac{p_\theta(x, z)}{q_\phi(z|x)} dz$$

여러 개의 데이터에 대한 ELBO

$$\sum_{n=1}^N \text{ELBO}(x^{(n)}; \theta, \phi) = \sum_{n=1}^N \int q_\phi(z|x^{(n)}) \log \frac{p_\theta(x^{(n)}, z)}{q_\phi(z|x^{(n)})} dz$$

2점 ELBO 최적화 공식은 ???

$$\text{ELBO}(x; \theta, \phi) = \int q_\phi(z|x) \log \frac{p_\theta(x, z)}{q_\phi(z|x)} dz$$

$$= \int q_\phi(z|x) \log \frac{p_\theta(x|z) p(z)}{q_\phi(z|x)} dz$$

$$= \int q_\phi(z|x) \log p_\theta(x|z) dz - \int q_\phi(z|x) \log \frac{q_\phi(z|x)}{p(z)} dz$$

$$= \underbrace{E_{q_\phi(z|x)} [\log p_\theta(x|z)]}_{J_1} - \underbrace{D_{KL}(q_\phi(z|x) \| p(z))}_{J_2}$$

$J_1$  = 기댓값

= 재구성 오차

(reconstruction error)

or

재구성 손실

$J_2$  = KL 발산

= 정규화


(regularization)

or

일관성 항

$J_1$  계산  $\rightarrow$  몬테카를로!

즉  $\mu, \sigma = \text{NeuralNet}(x; \phi)$   
 $z \sim N(z; \mu, \sigma^2 I)$   
 $\hat{x} = \text{NeuralNet}(z; \theta)$   
 $J_1 \approx \log N(x; \hat{x}, I)$



$J_1 \approx \log N(x; \hat{x}, I)$   
 $= \log \left( \frac{1}{\sqrt{(2\pi)^D |I|}} \exp \left( -\frac{1}{2} (x - \hat{x})^T I^{-1} (x - \hat{x}) \right) \right)$   
 $= -\frac{1}{2} (x - \hat{x})^T (x - \hat{x}) + \log \frac{1}{\sqrt{(2\pi)^D}}$   
 $= -\frac{1}{2} \sum_{d=1}^D (x_d - \hat{x}_d)^2 + \text{const}$

$J_2$  계산

$q_\phi(z|x) = N(z; \mu, \sigma^2 I)$   
 $p(z) = N(z; 0, I)$   
 $J_2 = \text{D}_{KL}(q_\phi(z|x) \| p(z))$   
 $= -\frac{1}{2} \sum_{h=1}^H (1 + \log \sigma_h^2 - \mu_h^2 - \sigma_h^2)$

즉 ELBO!

$\text{ELBO}(x; \theta, \phi) \approx -\frac{1}{2} \sum_{d=1}^D (x_d - \hat{x}_d)^2 + \frac{1}{2} \sum_{h=1}^H (1 + \log \sigma_h^2 - \mu_h^2 - \sigma_h^2) + \text{const}$

이때  $z \sim N(x; \mu, \sigma^2 I)$ 에서  $z$ 에 대한 표현 (공제)

따라서,  $z = \mu + \sigma \epsilon$  (reparameterization trick)  
 $\epsilon \sim N(\epsilon; 0, I) \Rightarrow z = \mu + \sigma \odot \epsilon$   
 $\uparrow$   
 Hadamard product

# 7.4 VAE 구현

VAE 목표 = ELBO 최대화

$$\text{ELBO}(x; \theta, \phi) \approx -\frac{1}{2} \sum_{d=1}^D (x_d - \hat{x}_d)^2 + \frac{1}{2} \sum_{h=1}^H (\log \sigma_h^2 - \mu_h^2 - \sigma_h^2) + \text{const}$$

이론상 증명 손실 함수 최소화! 따라서

$$\text{Loss}(x; \theta, \phi) \approx \sum_{d=1}^D (x_d - \hat{x}_d)^2 - \sum_{h=1}^H (\log \sigma_h^2 - \mu_h^2 - \sigma_h^2)$$

즉, VAE의 학습 계산 그래프는

