


# Ch 01. 정규분포

---

1. 확률의 기초
2. 정규 분포
3. 중심 극한 정리
4. 풀본 합의 확률 분포
5. 우리 주변의 정규분포



# 1.1 확률의 기초

## 1.1.1 확률 변수와 확률 분포



$x = \{1, 2, 3, 4, 5, 6\} \rightarrow$  표본 or 생물  
 $\left\{ \frac{1}{6}, \dots, p(x=3), \dots, \frac{1}{6} \right\} \rightarrow$  확률 분포  
 모두 같은 확률  $\rightarrow$  균등 분포

## 1.1.2 확률 분포의 종류

이산 확률 분포  $\Rightarrow$   $x$ 가 이산값  $\Rightarrow$

연속 확률 분포  $\Rightarrow$   $x$ 가 연속값  $\Rightarrow$

## 1.1.3 기댓값과 분산

기댓값 = 평균

$$\text{이산 } E[x] = \sum_{x=1}^N x_k p(x_k)$$

$$\text{연속 } E[x] = \int_{-\infty}^{\infty} x p(x) dx$$

분산은  $(x-\mu)^2$ 의 기댓값

$$\text{Var}[x] = E[(x-\mu)^2] = \sum_{k=1}^N (x_k - \mu)^2 p(x_k)$$

$$\text{Var}[x] = E[(x-\mu)^2] = \int_{-\infty}^{\infty} (x - \mu)^2 p(x) dx$$

확률 분포가 되기 위한 조건

이산 확률 분포

$$1. 0 \leq p(x_k) \leq 1 \quad (k=1, \dots, N)$$

$$2. \sum_{k=1}^N p(x_k) = 1$$

연속 확률 분포

$$1. p(x) \geq 0$$

$$2. \int_{-\infty}^{\infty} p(x) dx = 1.$$

## 1.2 정규 분포

$$\text{정규 분포} = p(x; \mu, \sigma^2) = N(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$


평균  
표준 편차

만약  $\mu=0, \sigma=1$  일 때  $N(x; 0, 1) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$  ⇒ "정규 확률 분포"

if)  $\mu \Rightarrow \uparrow$



if)  $\sigma \Rightarrow \downarrow$



if)  $\sigma \Rightarrow \uparrow$



## 1.3 중심 극한 정리

모든 확률 분포  $p(x)$  →  $\{x^{(1)}, x^{(2)}, \dots, x^{(N)}\}$  (모든 경우)

$\bar{x} = \frac{x^{(1)} + x^{(2)} + \dots + x^{(N)}}{N}$

$\frac{\bar{x}_1}{p(\bar{x}; \mu, \sigma^2)} \rightarrow \frac{\bar{x}_2}{p(\bar{x}; \mu, \sigma^2)} \rightarrow \dots \rightarrow \frac{\bar{x}_k}{p(\bar{x}; \mu, \sigma^2)} \rightarrow \frac{\bar{x}}{N(\bar{x}; \mu, \frac{\sigma^2}{N})}$

if)  $N=1$       if)  $N=2$       ...      if)  $N=100 \uparrow$  더 확장

$\frac{\bar{x}}{p(\bar{x}; \mu, \sigma^2)}$   $\Rightarrow$   $\frac{\bar{x}}{N(\bar{x}; \mu, \frac{\sigma^2}{1})}$        $\frac{\bar{x}}{N(\bar{x}; \mu, \frac{\sigma^2}{4})}$        $\frac{\bar{x}}{N(\bar{x}; \mu, \frac{\sigma^2}{N})}$

# 1.4 표본합의 확률분포

$$\bar{x} = \frac{\overbrace{x^{(1)} + x^{(2)} + \dots + x^{(N)}}^N}{N} \Rightarrow S = x^{(1)} + x^{(2)} + \dots + x^{(N)} = N\bar{x}$$

표본합

즉 ①  $E[S] = E[N\bar{x}] = N E[\bar{x}] = N\mu$

②  $\text{Var}[S] = \text{Var}[N\bar{x}] = E[(N\bar{x} - N\mu)^2] = N\sigma^2$

증명 방법?

$P(x; \mu, \sigma^2)$  일 때!

$P(\bar{x}; \mu, \frac{\sigma^2}{N})$  이고!


$P(S; N\mu, N\sigma^2)$  이다!

) 그러면 풍차가 작아져?  
근데! 그러면 평균과 분산 모두 ↑

# Ch 02. 회대 가능도 추정


---

1. 생성 모델 개요
2. 실제 데이터로 생성 모델 유효하기
3. 회대 가능도 추정 이론
4. 생성 모델의 용도




## 2.1 생성 모델 개요


### 2.1.1 생성 모델의 목표



### 2.1.2 모집단과 샘플



### 2.3 최대 가능도 추정 이론



## 2.3.1 가능도 최적화

이제! 가능한수 =  $\theta$  라면, 여기서  $x$ 를 얻을 확률밀도 =  $p(x; \theta)$

그걸!

샘플링  $D = \{x^{(1)}, x^{(2)}, \dots, x^{(N)}\}$  일 때!

•  $\text{경일을 확률밀도} = p(D; \theta) = p(x^{(1)}; \theta) p(x^{(2)}; \theta) \cdots p(x^{(N)}; \theta)$

$$= \prod_{n=1}^N p(x^{(n)}; \theta)$$

• 가능한수 =  $\theta$  일 때,  $D$ 를 얻을 확률이다!

이걸,  $\theta$ 를 얻고 받는 함수!라고 하면! 아래처럼 표현!

$$\begin{aligned} L(\theta) &= p(D; \theta) = \text{가능도 (likelihood)} \\ &= \text{가능도 함수 (likelihood function)} \end{aligned}$$

여기서 \*

$$\log L(\theta) = \log p(D; \theta) = \text{로그 가능도}$$

가장 여기서 가능도의 최적화란?  
 $\theta$ 를 잘 찾아서!  
 $D$ 가 딱 맞는 분포를 찾는거지!  
즉!  $D$ 를 얻을 확률을 \*  
'최적화' 하는 것이라!

## 2.3.2 평균 분포의 최대 가능도 추정

$$N(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

\$\xrightarrow{\text{설명}} D = \{x^{(1)}, x^{(2)}, \dots, x^{(N)}\} \xrightarrow{\text{설명}} p(D; \mu, \sigma^2) = \prod\_{n=1}^N p(x^{(n)}; \mu, \sigma^2)

이게 가능도!

$$\begin{aligned} \log p(D; \mu, \sigma^2) &= \log \prod_{n=1}^N p(x^{(n)}; \mu, \sigma^2) \\ &= -\frac{N}{2} \log 2\pi\sigma^2 - \frac{1}{2\sigma^2} \sum_{n=1}^N (x^{(n)} - \mu)^2 \end{aligned}$$

이게 고려 가능도!

자! 여기서도 최대 가능도를 어떻게 얻을까?

→ 어떤든  $\log p(D; \mu, \sigma^2)$ 가 최대화 되는  $\mu, \sigma^2$ 를 찾아야 하지

→ 2계 미분?

→ 2계 미분값  $= 0$ 이 되는 곳?

→ 아... 2계 조건이... 2계 힌트... 끝에 계수가 0인...

→ 2계로 가능도를 봐야...!!!

→ 찾았드라!!!

결국:  $\mu$ 와  $\sigma^2$ 로 편미분하면!!! → 아래식! → 외. 증명도 있드라!!!


$$\begin{aligned} \frac{\partial \log p(D; \mu, \sigma^2)}{\partial \mu} &= 0 \\ \Leftrightarrow \mu &= \frac{1}{N} \sum_{n=1}^N x^{(n)} \\ &= \hat{\mu} \end{aligned}$$

$$\begin{aligned} \frac{\partial \log p(D; \mu, \sigma^2)}{\partial \sigma^2} &= 0 \\ \Leftrightarrow \sigma^2 &= \sqrt{\frac{1}{N} \sum_{n=1}^N (x^{(n)} - \hat{\mu})^2} \\ &= \hat{\sigma}^2 \end{aligned}$$

## Ch 03. 다변량 정규 분포


---

1. 널화이와 다차원 배열
2. 다변량 정규 분포
3. 2차원 정규 분포 시각화
4. 다변량 정규 분포의 회의 가능성 추정



### 3.1 넘파이와 다차원 배열

#### 3.1.1 다차원 배열



#### 3.1.3 원소별 연산

$$\begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \Rightarrow \text{원소별 합}$$

$$\begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \times \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \Rightarrow \text{원소별 곱} \Rightarrow \text{아다마드 곱 (Hadamard product)}$$

#### 3.1.4 벡터의 내적과 행렬곱

$$\begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \bullet \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} = \Delta + \Delta + \Delta \Rightarrow \text{벡터의 내적}$$

$$\begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \bullet \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} = \Delta \Delta + \Delta \Delta + \Delta \Delta + \Delta \Delta \Rightarrow \text{행렬곱}$$

## 3.2 다변량 정규 분포

### 3.2.1 다변량 정규 분포 공식

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{pmatrix} \Rightarrow N(x; \mu, \Sigma) = \frac{1}{\sqrt{(2\pi)^p |\Sigma|}} \exp \left\{ -\frac{1}{2} (x-\mu)^T \Sigma^{-1} (x-\mu) \right\}$$

도수분포  
평균 벡터  
 $= \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{pmatrix}$   
공분산 행렬  
 $= \begin{pmatrix} b_{11} & b_{12} & \cdots & b_{1D} \\ b_{21} & b_{22} & & \\ \vdots & & \ddots & \\ b_{D1} & & & b_{DD} \end{pmatrix}$

여기서!  
 $b_{11}, b_{22}, \dots, b_{DD} \rightarrow$  분산  $\Rightarrow x_n$  가 얼마나 흩어졌는지 보여줘!  
 $b_{12}, b_{21}, \dots \rightarrow$  공분산  $\Rightarrow x_n$  과  $x_j$ 의 연관성을 보여줘!

2점. 공분산은 어떻게 계산?

$$\text{분산} = \text{Var}[x_n] = E[(x_n - \mu_n)^2]$$

$\rightarrow$  요고 와꿔!

$$\xleftrightarrow{\text{공분산}} \text{공분산} = \text{Cov}[x_n, x_j] = E[(x_n - \mu_n)(x_j - \mu_j)]$$

2점. 전치는?

$$x = (1, 2, 3) \xrightarrow{\text{전치}} x^T = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$$

2점 행렬식은?

이거 알주? determinant?

2점. 역행렬은?

$$AA^{-1} = A^{-1}A = I \Rightarrow \text{inverse matrix}?$$

### 3.4 다변량 정규 분포의 최대 가능도 추정

#### 3.4.1 최대 가능도 추정하기

$$N(x; \mu, \Sigma) = \frac{1}{\sqrt{(2\pi)^D |\Sigma|}} \exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\}$$

만약 샘플  $D = \{x^{(1)}, x^{(2)}, \dots, x^{(N)}\}$  이면!  $\Rightarrow D$  가 샘플임을 확인하라.

$$\begin{aligned} p(D; \mu, \Sigma) &= N(x^{(1)}; \mu, \Sigma) N(x^{(2)}; \mu, \Sigma) \cdots N(x^{(N)}; \mu, \Sigma) \\ &= \prod_{n=1}^N N(x^{(n)}; \mu, \Sigma) \end{aligned}$$

\$\xrightarrow{\text{만약 } \Sigma \text{ 가 대각행렬 일 때,}}\$  
\$\xrightarrow{\text{모든 고장과 같아?}}\$  
샘플  $D$ 를 얻을 확률 정도.

따라서!

$$p(D; \mu, \Sigma) = L(\mu, \Sigma) = \text{가능도} = \text{가능도 } \xrightarrow{\text{함수}}$$

혹은! \$\hookrightarrow \log p(D; \mu, \Sigma)\$

여기로 미분하지! ~~최대 가능도~~


$$\frac{\partial L}{\partial \mu} = 0 \Rightarrow \hat{\mu} = \frac{1}{N} \sum_{n=1}^N x^{(n)}$$

$$\frac{\partial L}{\partial \Sigma} = 0 \Rightarrow \hat{\Sigma} = \frac{1}{N} \sum_{n=1}^N (x^{(n)} - \hat{\mu})(x^{(n)} - \hat{\mu})^T$$

## Ch 04. 가우스 혼합 모델



---

1. 우리 주변의 대상 분포
2. 가우스 혼합 모델 데이터 생성
3. 가우스 혼합 모델의 수식
4. 매개변수 추정의 어려움



## 4.1 우리 주변의 대분 분포

### 가우스 분포



## 4.2 가우스 혼합 모델 데이터 생성


모든 대분 분포  $\xrightarrow{\text{Wow!}}$  GMM으로 표현 가능!  $\xrightarrow{\text{근데!}}$  2 가지 각성이 필요!

1! 모델링: 관측 데이터의 분포를 GMM으로 표현할 수 있다고  $\xrightarrow{\text{가능!}}$

2! 매개변수 추정: GMM의 매개 변수 추정

$\hookrightarrow$  근데! 이런 회의 가능으로 안돼 ㅠㅠ  $\rightarrow$  그래서! EM! 을 사용

## 4.3 가우스 혼합 모델의 수식



근데!  $y$ 가 이미 일어난 상황에서  $x$ 의 발생 확률은? ㅠ  
 $\Rightarrow$  조건 확률  $\rightarrow$  특징 조건 확률!  
 (Conditional probability)

곱셈 정리!

$$\hookrightarrow p(x,y) = p(x|y) p(y)$$

주변 확률: 개별 사건 발생  $\xrightarrow{\text{결합에서 벌여가능!}}$   $p(x) = \sum_y p(x,y)$  or  $\int p(x,y) dy$

(marginal probability,  $p(x)$  or  $p(y)$ )

## GMM의 데이터 생성 결과!


→  $\pi$ 로  $K$ 개의 정규 분포를 준비!

그리고 반복!

1. 특정 확률 분포에 따라  $K$ 개의 정규분포 중 하나 선택!
2. 선택한 정규 분포에서 데이터 생성!


여기서!

이걸 범주형 분포 표현!



(categorical distribution)

$$p(z=k; \phi) = \phi_k$$



$D = \{x_1, \dots, x_n\}$  해서 선택!  
그리고 선택한 정규 분포에서 데이터 생성!

$p = \{x_1, \dots, x_n\}$

따라서 결과? GMM 추론 결과!

1.  $K$ 개 정규 분포 중 그 값에 따라 정규분포 선택! 즉!  $z=k$ 라면,  $x$ 가 따르는 확률 분포는  $K$ 번째!

따라서  $p(x|z=k; \mu, \Sigma) = N(x; \mu_k, \Sigma_k)$

2. 생성 모델의 목표! → 관측 데이터  $x$ 의 확률 분포  $p(x)$ 를 표현

따라서 주변과 A彤! →  $p(x) = \sum_{k=1}^K p(x, z=k)$

3. 이제, 결합 확률은?  $\pi_1, \pi_2, \dots, \pi_K$

$$\rightarrow p(x, z=k) = p(z=k) p(x|z=k) = \phi_k N(x; \mu_k, \Sigma_k)$$

4. 따라서  $\pi_1, \pi_2, \dots, \pi_K$  결합  $\pi$

$$\rightarrow p(x) = \sum_{k=1}^K \phi_k N(x; \mu_k, \Sigma_k)$$

#### 4.4 대개별수 추정의 어려움

GMM은 대개별수 추정이 어려워. ~

$$p(x; \phi, M, \Sigma) = \sum_{k=1}^K \phi_k N(x; \mu_k, \Sigma_k) \text{ 일 때 } \sim D = \{x^{(1)}, x^{(2)}, \dots, x^{(N)}\} \text{ 일 때 } \sim$$

$$p(D; \theta) = p(x^{(1)}; \theta) p(x^{(2)}; \theta) \cdots p(x^{(N)}; \theta) = \prod_{n=1}^N p(x^{(n)}; \theta) \Rightarrow \text{가능성이 } *$$

$$\log p(D; \theta) = \log \prod_{n=1}^N p(x^{(n)}; \theta)$$

$$= \sum_{n=1}^N \log p(x^{(n)}; \theta)$$

$$= \sum_{n=1}^N \log \left( \sum_{k=1}^K \phi_k N(x^{(n)}; \mu_k, \Sigma_k) \right) \Rightarrow \text{로그 가능성이 } *$$

로그-합! → 분자 해석 어려워 헛

(log-sum) 평균! 어려워 헛

합-로그! → 해석적으로 수월 헛

즉!  $\log p(D; \theta)$  또는 최대 가능로 어려워 헛 \*

## Ch 05. EM 알고리즘

---

1. KL 발산
  2. EM 알고리즘 도출 ①
  3. EM 알고리즘 도출 ②
  4. GMM과 EM 알고리즘
  5. EM 알고리즘 구현
- 
- 
- 
- 
- 

## 5.1 KL 발산

우선 표기법을 변경!

$$E_{p(x)}[f(x)] = \int f(x) p(x) dx \Rightarrow \text{연속 확률 변수 } x \text{ 가 있고 그 확률밀도가 } p(x) \text{ 일 때},$$

함수  $f(x)$ 의 기대값을 의미!

KL 발산 (클백-라이블러 발산, Kullback-Leibler divergence) 같?!?!


$\Rightarrow$  두 확률 분포의 차이!를 측정하는 지도!

$$\Rightarrow D_{KL}(p||q) = \int p(x) \log \frac{p(x)}{q(x)} dx \text{ 또는! } \sum_x p(x) \log \frac{p(x)}{q(x)}$$

KL 발산의 특징은?

1. 두 확률분포가 다른수록 값이 커진다!
2. 두 확률분포가 같으면 0이다!
3. 같지 않으면 0보다 크다!
4.  $D_{KL}(p||q)$ 와  $D_{KL}(q||p)$ 는 다르다!

KL 발산과 최대 가능도 추적의 관계



$p_x(x) \xrightarrow{\text{생성}} \{x^{(1)}, x^{(2)}, \dots, x^{(N)}\} \Rightarrow$  여기서  $p_\theta(x)$ 을 최대화하라!

$$\text{즉! } \log \prod_{n=1}^N p_\theta(x^{(n)}) = \sum_{n=1}^N \log p_\theta(x^{(n)})$$

$$\xrightarrow{\text{최적화}} \hat{\theta} = \arg \max_{\theta} \sum_{n=1}^N \log p_\theta(x^{(n)})$$

핵심 아이디어는?

$\star$   $p_x(x)$ 을  $p_\theta(x)$ 에 최대한 가깝게 맞춘다  
 $\Downarrow$

$p_x(x)$ 과  $p_\theta(x)$ 의 KL 발산을 최소화한다

$$\text{즉! } D_{KL}(p_x||p_\theta) = \int p_x(x) \log \frac{p_x(x)}{p_\theta(x)} dx \text{ 를 계산!}$$

$\star$  2214.  $p_x(x)$ 을 정확하게 몰라...

$\star$  2215. 몽티카로 방법 (Monte Carlo method)을 사용!

몬테카를로 방법은?

⇒ 확률분포 기대값의 근사값으로 구하는 방법!

⇒ 무작위 샘플 기반의 결과값의 평균을 구하는 방법!

⇒ 근사 방법은?

1.  $p_{\theta}(x)$ 에 따라 샘플  $\{x^{(1)}, x^{(2)}, \dots, x^{(N)}\}$  를 생성!
2. 각 데이터  $x^{(i)}$ 에서  $f(x^{(i)})$  를 구하고 평균을 구한다

$$\text{즉 } E_{p_{\theta}(x)}[f(x)] = \int p_{\theta}(x) f(x) dx$$

$$\approx \frac{1}{N} \sum_{n=1}^N f(x^{(n)}) \quad (x^{(n)} \sim p_{\theta}(x))$$

몬테카를로로 KL발산에 적용하면?

$$D_{KL}(p_{\theta} || p_{\phi}) = \int p_{\theta}(x) \log \frac{p_{\theta}(x)}{p_{\phi}(x)} dx$$

$$\approx \frac{1}{N} \sum_{n=1}^N \log \frac{p_{\theta}(x^{(n)})}{p_{\phi}(x^{(n)})} \quad (x^{(n)} \sim p_{\theta}(x))$$

$$= \frac{1}{N} \sum_{n=1}^N (\log p_{\theta}(x^{(n)}) - \log p_{\phi}(x^{(n)}))$$

여기서! 가장 작은 KL은?

$$\underset{\theta}{\operatorname{argmin}} D_{KL}(p_{\theta} || p_{\phi})$$

$$\underset{\theta}{\operatorname{argmin}} \left( -\frac{1}{N} \sum_{n=1}^N \log p_{\phi}(x^{(n)}) \right)$$


$$= \underset{\theta}{\operatorname{argmax}} \sum_{n=1}^N \log p_{\phi}(x^{(n)})$$

$$\text{즉! } \underset{\theta}{\operatorname{argmin}} D_{KL}(p_{\theta} || p_{\phi}) \approx \underset{\theta}{\operatorname{argmax}} \sum_{n=1}^N \log p_{\phi}(x_n)$$

즉! KL발산!

근데! 최대가능!

## 5.2 EM 알고리즘 흐름 ①



$$\log p_{\theta}(D) = \log (p_{\theta}(x^{(1)}) p_{\theta}(x^{(2)}) \cdots p_{\theta}(x^{(N)}))$$

$$= \sum_{n=1}^N \log p_{\theta}(x^{(n)})$$

$$= \sum_{n=1}^N \log \sum_{z^{(n)}} p_{\theta}(x^{(n)}, z^{(n)})$$

그러면? 1단계,

$$\log p_{\theta}(x) = \log \frac{p_{\theta}(x, z)}{p_{\theta}(z|x)}$$

$$= \log \frac{p_{\theta}(x, z) q(z)}{p_{\theta}(z|x) q(z)}$$

$$= \log \frac{p_{\theta}(x, z)}{q(z)} + \log \frac{q(z)}{p_{\theta}(z|x)}$$

$$\downarrow$$

아직 조건 가능성이 아님!

2단계 이걸 Kullback-Leibler으로 바꿔보기

이때 D 조건 가능성이 아님

이를 위해, 일의 차를  $q(z)$ 를 사용

2단계 2단계

$$\log p_{\theta}(x)$$

$$= \log p_{\theta}(x) \sum_z q(z)$$

$$= \sum_z q(z) \log p_{\theta}(x)$$

$$= \sum_z q(z) \left( \log \frac{p_{\theta}(x, z)}{q(z)} + \log \frac{q(z)}{p_{\theta}(z|x)} \right)$$

$$= \sum_z q(z) \log \frac{p_{\theta}(x, z)}{q(z)} + \sum_z q(z) \log \frac{q(z)}{p_{\theta}(z|x)}$$

$$= \sum_z q(z) \log \frac{p_{\theta}(x, z)}{q(z)} + D_{KL}(q(z), p_{\theta}(z|x))$$

이제 합 - 조건 가능도

즉, 주복

### 5.3 EM 알고리즘 적용 ②

$ELBO$  (Evidence Lower Bound, 증거 하한)은  $\geq 0$   $\Leftrightarrow$   $\left\{ \begin{array}{l} \text{가장 낮은 } 32 \text{ 가능성} \\ \text{에이.. 아무리 낮아도 이것보다 가능성이 낮을까..} \\ \text{로인 느낌} \end{array} \right.$

$$\log P_\theta(x) = \sum_z q(z) \log \frac{P_\theta(x, z)}{q(z)} + D_{KL}(q(z) || P_\theta(z|x))$$


$$\geq \sum_z q(z) \log \frac{P_\theta(x, z)}{q(z)} \Rightarrow ELBO \uparrow \Leftrightarrow D_{KL} \downarrow$$

$$ELBO(\mathcal{I}; q, \theta) = \sum_z q(z) \log \frac{P_\theta(x, z)}{q(z)}$$

자 그럼

$$\log P_\theta(x) = ELBO(\mathcal{I}; q, \theta) + D_{KL}(q(z) || P_\theta(z|x))$$

$\xrightarrow{\text{즉!}}$   $\log P_\theta(x)$ 는 일정  $ELBO \uparrow$  or  $D_{KL} \downarrow$



$$\xrightarrow{\text{즉!}} D_{KL} \text{ 최소화} = ELBO \text{ 최대화} = 21 \text{ 대 가능성}$$

21 대 가능성  $q(z)$  최적화  $\Rightarrow \theta = \theta_{old}$ 로 고정  $\xrightarrow{D_{KL}=0}$   $P_{\theta_{old}}(z|x) = q(z)$

$$\hookrightarrow ELBO(\mathcal{I}; q = P_{\theta_{old}}(z|x), \theta) = \sum_z P_{\theta_{old}}(z|x) \log \frac{P_\theta(x, z)}{P_{\theta_{old}}(z|x)}$$

$\circ [x]$  E-스텝  $\xrightarrow{(Expectation value-step)}$   $= E_{P_{\theta_{old}}(z|x)} \left[ \log \frac{P_\theta(x, z)}{P_{\theta_{old}}(z|x)} \right]$

21 대 가능성 다음은  $\theta$  최적화  $\Rightarrow \theta$ 에 대한 미분  $\Rightarrow$  최적  $\theta$  발견  $\Rightarrow \circ [x]$  M-스텝  
(Maximization-step)

이후 E-스텝, M-스텝 반복.. 즉!



## 2장 디아이터가 어떤 개수로 떠나?

단축  $D \cdot |G| = \{x^{(1)}, x^{(2)}, \dots, x^{(N)}\}$ , 임의 확률 셋  $\{q^{(1)}, q^{(2)}, \dots, q^{(M)}\}$  일 때

그림 3.2 가능도와 ELBO의 관계는?

$$\sum_{m=1}^M \log \sum_{z^{(m)}} p_\theta(x^{(m)}, z^{(m)}) \geq \sum_{m=1}^M \text{ELBO}(x^{(m)}; q^{(m)}, \theta) \\ = \sum_{m=1}^M \sum_{z^{(m)}} q^{(m)}(z^{(m)}) \log \frac{p_\theta(x^{(m)}, z^{(m)})}{q^{(m)}(z^{(m)})}$$

EM 알고리즘은?

1. E-스텝 :  $\{q^{(1)}, q^{(2)}, \dots, q^{(M)}\}$  고정 (θ 고정)

→ 각 m에 대해  $q^{(m)}(z) = p_\theta(z|x^{(m)})$  으로 정함.

2. M-스텝 : θ 고정 ( $\{q^{(1)}, q^{(2)}, \dots, q^{(M)}\}$  고정)

→  $\sum_{m=1}^M \text{ELBO}(x^{(m)}; q^{(m)}, \theta)$  가 최대가 되는 θ 찾기

3. 종료 : 이전 3.2 가능도와 이후 3.2 가능도 비교

즉? GMM에 대비한 EM은?

E-스텝은 각 k에 대해

$$q^{(m)}(k) = \frac{\phi_k N(x^{(m)}; \mu_k, \Sigma_k)}{\sum_{j=1}^K \phi_j N(x^{(m)}; \mu_j, \Sigma_j)}$$

진짜 GMM 중 k 파라미터 분포 강한 확률은?

종로 간접은 ↗ GMM으로 가능도

$$\frac{1}{N} \sum_{m=1}^N \log \sum_{j=1}^K \phi_j N(x^{(m)}; \mu_j, \Sigma_j)$$

↳ GMM 추적

↳ GMM 평균으로 가능도

M-스텝은 각 k에 대해

$$\phi_k = \frac{1}{N} \sum_{m=1}^N q^{(m)}(k)$$

$$\mu_k = \frac{\sum_{m=1}^N q^{(m)}(k) x^{(m)}}{\sum_{m=1}^N q^{(m)}(k)}$$

$$\Sigma_k = \frac{\sum_{m=1}^N (q^{(m)}(k)(x^{(m)} - \mu_k)(x^{(m)} - \mu_k)^T)}{\sum_{m=1}^N q^{(m)}(k)}$$

모든 데이터에 대한 계산!

k 번째 파라미터 기반으로


진짜 데이터에 대입???

이후, 가장 적절한 파라미터 선택???

# Ch 06. 선정망

---

1. 파일트리와 경사법
2. 선형 회귀
3. 대개별수와 풍터마이너
4. 선정망 주제
5. 트리 바 реша 데이터셋



## 6.2 선형 회귀

$$y \text{가 } x \text{의 선형} \Rightarrow \hat{y} = w_x + b$$

이때  $y - \hat{y}$  가 정규분포를 따릅니다고 가정

$\Rightarrow y - \hat{y}$  이 평균 0, 표준편차  $b$ 를 따릅니다고 가정

즉  $y$ 는 평균  $\hat{y}$ , 표준편차  $b$ 인 정규분포를 따릅니다!

이는?

$$\hat{y} = w_x + b$$

$$p(y|x; w, b) = N(y; \hat{y}, b)$$

따라서 32 가능합니다!

$$\log p(y|x; w, b)$$

$$= \log N(y; \hat{y}, b)$$

$$= -\frac{1}{2b^2} (y - w_x - b)^2 + \log \frac{1}{\sqrt{2\pi b^2}}$$

하여 32 가능합니다!

$$\underset{w, b}{\operatorname{argmax}} \log p(y|x; w, b)$$

$$= \underset{w, b}{\operatorname{argmax}} \left( -\frac{1}{2b^2} (y - w_x - b)^2 \right)$$

$$= \underset{w, b}{\operatorname{argmin}} (y - (w_x + b))^2$$

2) 회귀 함수 (실际 함수)입니다

$$L(w, b) = \frac{1}{N} \sum_{n=1}^N (y^{(n)} - (w_x^{(n)} + b))^2$$


이것이!

평균 제곱 오류 (mean squared error, mse)입니다


# Ch 07. 변이형 오토인코더

---

1. VAE와 디코더
2. VAE와 인코더
3. ELBO 최적화
4. VAE 구현



## 7.1 VAE와 디코더



### 하나의 정규분포는?

매개변수  $\theta = \{\mu, \Sigma\}$ , 데이터  $x$   $\Rightarrow$  확률 분포  $= P_\theta(x) = N(x; \theta)$  이고!

$N$ 개 관측치인  $D = \{x^{(1)}, x^{(2)}, \dots, x^{(N)}\}$   $\xrightarrow{\text{가능성}} \log P_\theta(D) = \log(P_\theta(x^{(1)}) P_\theta(x^{(2)}) \dots P_\theta(x^{(N)}))$

### GMM은?

1. 범주형 분포에 따라  $k$ 개의 정규분포 중 하나를 선택  $\Rightarrow$  ELBO를 목적함수로!  $\Rightarrow$  EM 알고리를 수행!
2. 선택한 정규분포에서 데이터를 생성

이제 ELBO는


$$\log P_\theta(D) \geq \sum_{n=1}^N \sum_{z^{(n)}} q^{(n)}(z^{(n)}) \log \frac{P_\theta(x^{(n)}, z^{(n)})}{q^{(n)}(z^{(n)})}$$

### VAE는?

VAE의 디코더 사용 과정

1. 현재 범주  $z$ 를 고정된 정규 분포에서 생성!
2. 선형망을 통해  $z$ 를  $x$ 로 변환!

디코더 (decoder)




다각화!  
•  $\hat{x} = \text{NeuralNet}(z; \theta)$   $\xrightarrow{\text{생물학}} \text{선형망의 매개변수}$

$P_\theta(x|z) = N(x; \mu, I) \Rightarrow x$ 는  $z$ 에 따른 확률 분포를 따릅니다!

목표: 실제 범주  $z$ 의 확률 분포  $P(z)$ 를 얻기!  
이를 위해 선형망  $P(x|z)$ 을 보정함!  
( $z \rightarrow x$ )

## VAE의 디코더의 성능



2번 EM으로 할 수 있나?  $\rightarrow \text{No!}$


$$\begin{aligned} \text{VAE에서 E-스텝} \rightarrow q^{(m)}(z) &= p_{\theta}(z|x^{(m)}) = \frac{p_{\theta}(x^{(m)}, z)}{p_{\theta}(x^{(m)})} \\ &= \underbrace{\frac{p_{\theta}(x^{(m)}, z)}{\int p_{\theta}(x^{(n)}, z) dz}}_{\text{GMM : 이산 } \rightarrow \sum \rightarrow \text{계산량 } \downarrow} \\ &\quad \text{VAE : 연속 } \rightarrow \int \rightarrow \text{계산량 } \uparrow \end{aligned}$$

## 1.2 VAE의 알고리즘

EM 알고리즘!

$$\log P_{\theta}(x) = \int q(z) \log \frac{P_{\theta}(x, z)}{q(z)} dz + \underbrace{D_{KL}(q(z) || P_{\theta}(z|x))}_{\text{KL변수}}$$


$$\geq \int q(z) \log \frac{P_{\theta}(x, z)}{q(z)} dz$$



즉  $q_{\psi}(z) = N(z; \mu, \Sigma)$  → 험장!

따라서  $\log P_{\theta}(x) = \int q_{\psi}(z) \log \frac{P_{\theta}(x, z)}{q_{\psi}(z)} dz + D_{KL}(q_{\psi}(z) || P_{\theta}(z|x))$

ELBO 최대화  $\rightarrow$   $ELBO(x; \theta, \psi) = \int q_{\psi}(z) \log \frac{P_{\theta}(x, z)}{q_{\psi}(z)} dz$



중요  $P_{\theta}(z|x)$  와  $q_{\psi}(z)$  가 같지 않아!

즉  $q_{\psi}(z)$  를 해석하!

이걸로 베이즈 (Variational approximation)  
라고 한다!  
or  
베이즈 베이스 (Variational bayes)

라고 한다!

2점 문제 데이터에서는 ???

$$\sum_{n=1}^N \text{ELBO}(x^{(n)}; \phi, \psi^{(n)}) = \sum_{n=1}^N \int q_{\psi^{(n)}}(z) \log \frac{p_{\theta}(x^{(n)}, z)}{q_{\psi^{(n)}}(z)} dz$$

\*  $x^{(n)}$ 은 ...  $N$ 개 ...  
→ 문제 이점  $q_{\psi^{(n)}}(z)$ 이  $N$ 개 필요 ...  
너무 많아!



??

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix}, \quad \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_N \end{pmatrix}, \quad b = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_N \end{pmatrix}, \quad z = \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_N \end{pmatrix}$$

따라서 VAE 인코더가 하는 일은!

$$\mu, b = \text{NeuralNet}(x; \phi) \rightarrow (\Sigma) \rightarrow \text{평균 행렬}$$

$$q_{\phi}(z|x) = N(z; \mu, b^2 I)$$



즉 근사 A 후 분포  $p_{\theta}(x|z)$ 을  
신경망으로 계산하는 방법을 찾음  
분할 상관 추론?  
(amortized inference)

### 7.3 ELBO 죄격학

VAE 이코더

$$p(z) = N(z; 0, I)$$

$$\hat{z} = \text{NeuralNet}(z; \theta)$$

$$p_{\theta}(x|z) = N(x; \hat{z}, I)$$

VAE 오코더

$$\mu, b = \text{NeuralNet}(x; \phi)$$

$$q_{\phi}(z|x) = N(z; x, \mu, b^2 I)$$

하나의 데이터에 대한 ELBO

$$\text{ELBO}(x; \theta, \phi) = \int q_{\phi}(z|x) \log \frac{p_{\theta}(x, z)}{q_{\phi}(z|x)} dz$$

여러 개의 데이터에 대한 ELBO

$$\sum_{m=1}^N \text{ELBO}(x^{(m)}; \theta, \phi) = \sum_{m=1}^N \int q_{\phi}(z|x^{(m)}) \log \frac{p_{\theta}(x^{(m)}, z)}{q_{\phi}(z|x^{(m)})} dz$$

2번 ELBO 최대화 궁금은 ???

$$\text{ELBO}(x; \theta, \phi) = \int q_{\phi}(z|x) \log \frac{p_{\theta}(x, z)}{q_{\phi}(z|x)} dz$$

$$= \int q_{\phi}(z|x) \log \frac{p_{\theta}(x|z) p(z)}{q_{\phi}(z|x)} dz$$

$$= \int q_{\phi}(z|x) \log p_{\theta}(x|z) dz - \int q_{\phi}(z|x) \log \frac{q_{\phi}(z|x)}{p(z)} dz$$

$$= E_{q_{\phi}(z|x)} [\log p_{\theta}(x|z)] - D_{KL}(q_{\phi}(z|x) || p(z))$$

$$J_1 = \text{reconstruction err}$$

= 재구성 오류  
(reconstruction error)

or

재구성 오류

$$J_2 = \text{KL } D_{KL}$$


= 정규화  
(regularization)

or

정규화 항  
(regularization term)

J<sub>1</sub> 계산 → 물리적으로!

즉  $\mu, \sigma = \text{NeuralNet}(x; \theta)$   
 $z \sim N(z; \mu, \sigma^2 I)$   
 $\hat{x} = \text{NeuralNet}(z; \theta)$   
 $\checkmark J_1 \approx \log N(x; \hat{x}, I)$



$J_1 \approx \log N(x; \hat{x}, I)$

$$= \log \left( \frac{1}{\sqrt{(2\pi)^D |I|}} \exp \left( -\frac{1}{2} (x - \hat{x})^T I^{-1} (x - \hat{x}) \right) \right)$$

$$= -\frac{1}{2} (x - \hat{x})^T (x - \hat{x}) + \log \frac{1}{\sqrt{(2\pi)^D}}$$

$$= -\frac{1}{2} \sum_{d=1}^D (x_d - \hat{x}_d)^2 + \text{const}$$

const:  $\frac{1}{2} \log |I|$

J<sub>2</sub> 계산

$$\begin{aligned} q_\phi(z|x) &= N(z; \mu, \sigma^2 I) \\ p(z) &= N(z; 0, I) \end{aligned} \Rightarrow J_2 = D_{KL}(q_\phi(z|x) || p(z))$$

$$= -\frac{1}{2} \sum_{h=1}^H (1 + \log \sigma_h^2 - \mu_h^2 - \sigma_h^2)$$

즉! ELBO는!

$$\text{ELBO}(x; \theta, \phi) \approx -\frac{1}{2} \sum_{d=1}^D (x_d - \hat{x}_d)^2 + \frac{1}{2} \sum_{h=1}^H (1 + \log \sigma_h^2 - \mu_h^2 - \sigma_h^2) + \text{const}$$

ELBO는 정의

이거!  $z \sim N(z; \mu, \sigma^2 I)$ 에서  $z$ 에 대한 비중이 있는가?

따라서,  $z$ 의 가중치화된 확률  $\Rightarrow g \sim N(\epsilon; 0, I) \Rightarrow z = \mu + \sigma \odot g$

(reparameterization trick)

$\uparrow$  적당한 곱  
Hadamard product)

## 7.4 VAE 구현


VAE 목표 = ELBO 최대화

$$ELBO(x_i; \theta, \phi) \approx -\frac{1}{2} \sum_{d=1}^D (x_d - \hat{x}_d)^2 + \frac{1}{2} \sum_{h=1}^H (\log b_h^2 - \mu_h^2 - b_h^2) + \text{const}$$

이는 즉, 손실 학습 최소화!

\*  $\text{Loss}(x; \theta, \phi) \approx \sum_{d=1}^D (x_d - \hat{x}_d)^2 - \sum_{h=1}^H (\log b_h^2 - \mu_h^2 - b_h^2)$

즉, VAE의 학습 계산 과정은?



# Ch 08. 확산 모델 이론


---

1. VAE에서 확산 모델로
  2. 확산 과정에서 역확산 과정
  3. ELBO 계산 ①
  4. ELBO 계산 ②
  5. ELBO 계산 ③
  6. 확산 모델의 학습 (알고리즘)
- 
- 
- 
- 
- 

## 8.1 VAE에서 확산 모델로

DDPM → 확산모델


(Denoising Diffusion Probabilistic Models,  
노이즈 추가 확산 확률 모델)



확산모델은!

① 관측 변수와 잠재 변수의 차원 일치!  
⇒ 확산모델!


제동형 VAE + ② 고정된 정규 분포를 따르는 노이즈를 일로미에 추가!



## 8.2 확산 과정과 역확산 과정

확산 모델  $\begin{cases} \text{확산 과정: 노이즈를 추가하는 과정} \\ \text{역확산 과정: 노이즈를 제거하는 과정} \end{cases}$

### 확산 과정 (diffusion process)




증명:  $p(x_t) \approx N(x_t; 0, I)$

이제  $x_t$ 가  $x_{t-1}$ 에 영향을 미치는 토록  $\beta_t$ 를 정함.

$$\begin{aligned} G &\sim N(G; 0, I) \\ \therefore x_t &= \sqrt{1-\beta_t} x_{t-1} + \sqrt{\beta_t} G \end{aligned}$$

### 역확산 과정 (reverse diffusion process)



증명:  $\hat{x}_{t-1} = \text{NeuralNet}(x_t, t; \theta)$

$\therefore p_\theta(x_{t-1} | x_t) = N(x_{t-1}; \hat{x}_{t-1}, I)$

모든 과정 예상(예측)  
적용 가능한 공분산 행렬

## 8.3 ELBO 계산 ①

확산 모델  $\rightarrow$  ELBO  $\rightarrow$  근사값  $\xrightarrow{\text{우선!}}$  최종 시간 =  $T \Rightarrow T$ 개 샘플 데이터  $x_1, x_2, \dots, x_T$  확률!

확산 모델의 ELBO

$$\text{VAE의 ELBO } (x; \theta, \phi) = \int q_{\phi}(z|x) \log \frac{p_{\theta}(x, z)}{q_{\phi}(z|x)} dz \\ = E_{q_{\phi}(z|x)} \left[ \log \frac{p_{\theta}(x, z)}{q_{\phi}(z|x)} \right]$$

알아두기!

$$P_{\theta}(x_0:T) = p_{\theta}(x_0|x_1)p(x_1|x_2)\dots p_{\theta}(x_{T-1}|x_T)p(x_T) \\ = P(x_T) \prod_{t=1}^T p_{\theta}(x_{t-1}|x_t)$$

$$q(x_1:T|x_0) = \prod_{t=1}^T q(x_t|x_{t-1})$$

즉:

$$J(\theta) = E_{q(x_1:T|x_0)} \left[ \log \prod_{t=1}^T p_{\theta}(x_{t-1}|x_t) \right] \\ = E_{q(x_1:T|x_0)} \left[ \sum_{t=1}^T \log p_{\theta}(x_{t-1}|x_t) \right]$$

따라서! 몽테 카를o 사용!

$$\Downarrow$$
  
 여기까지 알고리즘  
 $\Downarrow$   
 $\sum_{t=1}^T \log p_{\theta}(x_{t-1}|x_t)$  평균 계산

샘플 크기가 1이 아닐 때  $\xrightarrow{\text{J}(\theta) \approx \sum_{t=1}^T \log p_{\theta}(x_{t-1}|x_t)}$

3가지 방법

1.  $x \rightarrow x_0$
2.  $z \rightarrow x_{1:T}$
3.  $\phi$  학습

확산 모델의 ELBO  $(x_0; \theta) = E_{q(x_{1:T}|x_0)} \left[ \log \frac{p_{\theta}(x_0:T)}{q(x_{1:T}|x_0)} \right]$

ELBO  $(x_0; \theta)$

$$= E_{q(x_{1:T}|x_0)} \left[ \log \frac{p_{\theta}(x_0:T)}{q(x_{1:T}|x_0)} \right] \\ = E_{q(x_{1:T}|x_0)} \left[ \log \frac{p(x_T) \prod_{t=1}^T p_{\theta}(x_{t-1}|x_t)}{\prod_{t=1}^T q(x_t|x_{t-1})} \right] \\ = E_{q(x_{1:T}|x_0)} \left[ \underbrace{\log \prod_{t=1}^T p_{\theta}(x_{t-1}|x_t)}_{\text{부정합}} + \log \frac{p(x_T)}{\prod_{t=1}^T q(x_t|x_{t-1})} \right] \quad \text{부정합} \quad \text{비정합}$$

증명

$$\text{원본 } x_0 \xrightarrow{\text{NN}} x_{1:T} \xrightarrow{\text{각 시각에 대한 계산}} \log p_\theta(x_{t+1}|x_t)$$

\*  $\hat{x}_{t+1} = \text{NeuralNet}(x_t, t; \theta) *$

\*  $p_\theta(x_{t+1}|x_t) = N(x_{t+1}; \hat{x}_{t+1}, I) *$

도함수

$$J(\theta) \approx \sum_{t=0}^T \log p_\theta(x_{t+1}|x_t)$$

↑ 시각 번호 변화.  
↑ 정규 분포 사용

$$= \sum_{t=0}^T \log N(x_{t+1}; \hat{x}_{t+1}, I)$$

$$= \sum_{t=0}^T \log \frac{1}{\sqrt{(2\pi)^p |I|}} \exp \left\{ -\frac{1}{2} (x_t - \hat{x}_t)^T I^{-1} (x_t - \hat{x}_t) \right\}$$

$$= -\frac{1}{2} \sum_{t=0}^T (x_t - \hat{x}_t)^T (x_t - \hat{x}_t) + T \log \frac{1}{\sqrt{(2\pi)^p}}$$

$$= -\frac{1}{2} \sum_{t=0}^T \|x_t - \hat{x}_t\|^2$$

상수  $\rightarrow$  무시

증명 목적 함수  $J(\theta)$ 는!

1. 확산 과정을 통해 T개 샘플 얻기!

2. 선형방정식 T번 적용해서 빠르게 계산

3. 각 A각의 계산과  $\|x_t - \hat{x}_t\|^2$  계산

$\Rightarrow$  'T' 번이나...? 너무 많잖아...-

## 8.4 ELBO 계산 ②

역시! T개는 너무 많아요  $\xrightarrow{\text{다시 풀기}}$  2개로 해보자


$$\text{증명} \quad q(x_t | x_0) = N(x_t; \hat{x}_t | x_0, (I - \hat{\alpha}_t) I) \xrightarrow{\text{가장}} \begin{aligned} \alpha_t &= 1 - \beta_t \\ \hat{\alpha}_t &= \alpha_t x_{t+1} \cdots x_1 \end{aligned}$$

우선  $J(\theta)$ 를 확장!

1. 유통분포  $U_{[1, T]}$ 에서 시작하는 샘플링
  2.  $q(x_t|x_0)$ 에서  $x_t$ 을 샘플링
  3.  $q(x_t|x_{t-1})$ 에서  $x_t$ 을 샘플링
  4. 선형방에  $x_t$ 을 입력!  $x_t$ 을 출력!
  5. 계산 오차  $\|x_t - \hat{x}_{t-1}\|^2$  계산!

## 8.5 ELBO 계산 ③

2번쨰 차례는 디 하나의 샘플 데이터로만 사용해서 ELBO를 구해보기



중요점!

이전 두 가지 ELBO  $q(x_{t-1}|x_t, x_0)$  형ELBO 한 가지 ELBO

주제!  $J(\theta) = \sum_{t=1}^T E_{q(x_{t-1}, x_t|x_0)} [\log p_\theta(x_{t-1}|x_t)]$

$= TE_{q(x_{t-1}, x_t|x_0)} [\log p_\theta(x_{t-1}|x_t)] \Rightarrow TE_{q(x_{t-1}, x_t|x_0)} [J_0]$

여기서  $q(x_{t-1}|x_t, x_0)^{\frac{1}{2}}$  추가됨

다시 계산!

$$\arg \max_{\theta} J_0 = \arg \max_{\theta} \left( J_0 - E_{q(x_{t-1}, x_t|x_0)} [\log q(x_{t-1}|x_t, x_0)] \right)$$

$$= \arg \max_{\theta} E_{q(x_{t-1}, x_t|x_0)} [\log p_\theta(x_{t-1}|x_t) - \log q(x_{t-1}|x_t, x_0)]$$

$$= \arg \max_{\theta} E_{q(x_{t-1}, x_t|x_0)} \left[ \log \frac{p_\theta(x_{t-1}|x_t)}{q(x_{t-1}|x_t, x_0)} \right] \xrightarrow{\text{A2번 } J(\theta) \text{ New}} J(\theta) = TE_{q(x_{t-1}, x_t|x_0)} [J_1]$$

$\hookrightarrow J_1$

그럼  $J_1$ 은 어떤 식인가?

$$\begin{aligned} J_1 &= \int q(x_{t-1}, x_t | x_0) \log \frac{p_\theta(x_{t-1} | x_t)}{q(x_{t-1} | x_t, x_0)} dx_{t-1} dx_t \\ &= -\int q(x_t | x_0) \int q(x_{t-1} | x_t, x_0) \log \frac{q(x_{t-1} | x_t, x_0)}{p_\theta(x_{t-1} | x_t)} dx_{t-1} dx_t \quad \xrightarrow{\text{KL 분산}} \\ &= -\mathbb{E}_{q(x_t | x_0)} \left[ D_{KL}(q(x_{t-1} | x_t, x_0) || p_\theta(x_{t-1} | x_t)) \right] \quad \xrightarrow{\text{즉각}} \\ &\quad \xrightarrow{\text{즉각}} \frac{1}{2\sigma_q^2(t)} \|\mu_\theta(x_t, t) - \mu_q(x_t, t)\|^2 \end{aligned}$$

즉각  
증명

$$\begin{aligned} \hat{x}_{t-1} &= \text{NeuralNet}(x_t, t; \theta) \quad \xrightarrow{\text{설정값을 통해}} \\ P_\theta(x_{t-1} | x_t) &= N(x_{t-1}; \hat{x}_{t-1}, \sigma_q^2(t) I) \quad \xrightarrow{\text{q}(x_{t-1} | x_t, x_0) \text{과 같은 확률}} \end{aligned}$$

$$\begin{aligned} J(\theta) &= -T \mathbb{E}_{q(x_t | x_0)} \left[ \mathbb{E}_{q(x_t | x_0)} \left[ \frac{1}{2\sigma_q^2(t)} \|\mu_\theta(x_t, t) - \mu_q(x_t, t)\|^2 \right] \right] \quad \xrightarrow{\text{즉각}} \\ \text{Loss}(x_0; \theta) &= \mathbb{E}_{q(x_t | x_0)} \left[ \mathbb{E}_{q(x_t | x_0)} \left[ \frac{1}{2\sigma_q^2(t)} \|\mu_\theta(x_t, t) - \mu_q(x_t, t)\|^2 \right] \right] \quad \xrightarrow{\text{즉각}} \\ &= \frac{1}{\sigma_q^2(t)} \|\mu_\theta(x_t, t) - \mu_q(x_t, t)\|^2 \end{aligned}$$

$t \sim \{1, T\}$   
 $x_t \sim q(x_t | x_0)$

## 8.6 확산 모델의 학습 (알고리즘)

### 확산 모델의 학습 알고리즘

1. 반복:

2.  $x_0$ 을 학습 데이터에서 분자위로 가져온

3.  $t \sim \{1, T\}$ ,  $\epsilon \sim N(0, I)$

4.  $x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon \leftarrow q(x_t | x_0)$ 에 따른 샘플링

5.  $\mu_q(x_t, x_0) = \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})x_t + \sqrt{\bar{\alpha}_{t-1}}(1 - \alpha_t)x_0}{1 - \bar{\alpha}_t}$

6.  $b_q^2(t) = \frac{(1 - \alpha_t)(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}$

7.  $\text{Loss}(x_0; \theta) = \frac{1}{b_q^2(t)} \|\mu_\theta(x_t, t) - \mu_q(x_t, x_0)\|^2$

8.  $\frac{\partial}{\partial \theta} \text{Loss}(x_0; \theta)$  계산

↓ 도식화



↓  $\mu_q(x_t, x_0) \leftarrow$  학습 데이터



★  $\mu_q(x_t, x_0)$ 은 학습 데이터로 하는 확산 모델 ★

## 원본 데이터를 복원하는 신경망

$$M_q(x_t, x_0) = \frac{\sqrt{d_t} (1 - \bar{d}_{t-1}) x_t + \bar{d}_{t-1} (1 - d_t) \hat{x}_0}{1 - \bar{d}_t}$$

$$M_\theta(x_t, t) = \frac{\sqrt{d_t} (1 - \bar{d}_{t-1}) x_t + \bar{d}_{t-1} (1 - d_t) \hat{x}_\theta(x_t, t)}{1 - \bar{d}_t}$$

신경망의 투영한 값

$$\begin{aligned} & D_{KL}(q(x_{t-1}|x_t, x_0) || p_\theta(x_{t-1}|x_t)) \\ \Rightarrow & = \frac{1}{2\sigma^2(t)} \| M_\theta(x_t, t) - M_q(x_t, x_0) \|^2 \\ & = \frac{1}{2\sigma^2(t)} \left( \frac{\sqrt{d_t}}{1 - \bar{d}_t} \right)^2 \| \hat{x}_\theta(x_t, t) - x_0 \|^2 \end{aligned}$$

↳ 솔루션 풀수 있다.

다시보기:



## 노이즈를 예측하는 신경망

$$q(x_t|x_0) = N(x_t; \sqrt{\bar{d}_t} x_0, (1 - \bar{d}_t)I)$$

$$\begin{aligned} & \downarrow \text{구현하기} \\ \varepsilon \sim N(0, I) \implies x_t = \sqrt{\bar{d}_t} x_0 + \sqrt{1 - \bar{d}_t} \varepsilon & \xrightarrow{\text{구현하기}} x_0 = \frac{x_t - \sqrt{1 - \bar{d}_t} \varepsilon}{\sqrt{\bar{d}_t}} \end{aligned}$$


증명

$$M_q(x_t, x_0) = \frac{1}{\sqrt{d_t}} \left( x_t - \frac{1 - \bar{d}_t}{\sqrt{1 - \bar{d}_t}} \varepsilon \right) \xrightarrow{\text{증명}} D_{KL}(q(x_{t-1}|x_t, x_0) || p_\theta(x_{t-1}|x_t)) \xrightarrow{\text{설명}} \text{설명할 수}$$

$$M_\theta(x_t, t) = \frac{1}{\sqrt{d_t}} \left( x_t - \frac{1 - \bar{d}_t}{\sqrt{1 - \bar{d}_t}} \varepsilon_\theta(x_t, t) \right)$$

$$= \frac{1}{2\sigma^2(t)} \frac{(1 - \bar{d}_t)^2}{(1 - \bar{d}_t)d_t} \| \varepsilon_\theta(x_t, t) - \varepsilon \|^2$$

다시보기:



## 새로운 데이터 샘플링

$$p_\theta(x_{t+1} | x_t) = N(x_{t+1}; \mu_\theta(x_t, t), \sigma^2_\theta(t) I)$$

↓ 재생성

$$\begin{aligned} \varepsilon \sim N(0, I) &\xrightarrow{\text{샘플링}} x_{t+1} = \mu_\theta(x_t, t) + \sigma_\theta(t) \varepsilon \\ \Rightarrow \mu_\theta(x_t, t) &= \frac{1}{\sqrt{\sigma_\theta^2}} \left( x_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}} \varepsilon_\theta(x_t, t) \right) \quad \sigma_\theta(t) = \sqrt{\frac{(1 - \alpha_t)(1 - \bar{\alpha}_{t+1})}{1 - \bar{\alpha}_t}} \end{aligned}$$

즉, 확산 보정의 데이터 생성 방법

1.  $x_T \sim N(0, I)$

2. for  $t \in [T-1]$ :

3.  $\varepsilon \sim N(0, I)$

4. if  $t=1$  then  $\varepsilon = 0$

5.  $\sigma_\theta(t) = \sqrt{\frac{(1 - \alpha_t)(1 - \bar{\alpha}_{t+1})}{1 - \bar{\alpha}_t}}$

6.  $x_{t+1} = \frac{1}{\sqrt{\sigma_\theta^2}} \left( x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \varepsilon_\theta(x_t, t) \right) + \sigma_\theta(t) \varepsilon$

7. return  $x_0$

# Ch 10. 확산 모델 응용

---

1. 조건부 확산 모델
2. 접수 함수
3. 분류기 가이던스
4. 분류기 없는 가이던스
5. 스테이블 디퓨전




# 10.1 3장부 확산 모델

기존

$p(x)$  모델링

3장부  
 $p(x|y)$  모델링  
 ↳ 텍스트, 이미지 ..

기존 신경망 모델링



$$p_\theta(x_{t+1}|x_t) = N(x_{t+1}; h_\theta(x_t, t), \sigma^2_\theta(t)I)$$

$$\text{여기서! } p_\theta(x_0) = \int p_\theta(x_0, x_1, \dots, x_T) dx_1 \dots dx_T$$



$$= \int p_\theta(x_0|x_0) p_\theta(x_1|x_0) \dots p_\theta(x_T|x_{T-1}) p(x_T) dx_1 \dots dx_T$$

) 3장 추가!

$$p_\theta(x_0|y) = \int p_\theta(x_0|x_0, y) \dots p_\theta(x_{T-1}|x_T, y) p(x_T) dx_1 \dots dx_T$$

즉!  $\star p_\theta(x_{t-1}|x_t, y) = N(x_{t-1}; h_\theta(x_t, t, y), \sigma^2_\theta(t)I) \star$

그럼  $\epsilon_\theta(x_t, t)$  에서는?



## 10.2 점수 함수

$p(x|y)$  → 단순 조건 → 무시 가능성 축약

이를 극복해 가이던스 (guidance) 사용  $\xrightarrow{\text{이는}}$  점수 함수 (score function) 사용

↳ 안내, 지침, 지도  
↳ 주어진 조건을 더 강조하여 반영하는 키워드

점수 함수는?

$$\star \varepsilon \approx -\sqrt{1-\bar{\alpha}_t} [\nabla_{x_t} \log p(x_t)] \rightarrow \text{로 가능한 } \log p(x_t) \text{의 임계 } x_t \text{에 대한 기울기}$$

※

즉  $\varepsilon$  또는 점수 함수

즉?

$x_t \rightarrow \text{NN}_{\theta} \rightarrow \varepsilon_{\theta}(x_t, t) \dots \text{②} \Rightarrow$  이것은  $\varepsilon$ 를 추적하는 신경망  
(가능도 기반 생성 모델, likelihood-based generative model)

점수 함수는?

$$\star \begin{array}{l} x_t \rightarrow \text{NN}_{\theta} \rightarrow \varepsilon_{\theta}(x_t, t) \dots \text{②} \\ t \rightarrow \text{NN}_{\theta} \end{array} \Rightarrow \frac{1}{\sqrt{1-\bar{\alpha}_t}} \varepsilon \leftarrow \text{점수 함수에서 } \frac{1}{\sqrt{1-\bar{\alpha}_t}} \varepsilon \text{와 } \varepsilon \text{는 } \nabla_{x_t} \log p(x_t) \text{의 마이너스 상수배 } (-\sqrt{1-\bar{\alpha}_t}) \text{ 와 같음}$$

※

다르다! BPP!

따라서?


$$-\frac{1}{\sqrt{1-\bar{\alpha}_t}} \varepsilon \text{은 학습 데이터!}$$

점수를 추적하는 신경망  
(점수 기반 생성 모델,  
(Score-based generative model)

## 10.3 분류기 가이던스

분류기 가이던스  $\Rightarrow$  분류기 사용을 활용하여 데이터 생성을 안내하는

(classifier guidance) (classifier)  $\Rightarrow$  데이터를 분류하는 학습된 신경망  $\Rightarrow$   $x_t \rightarrow NN(\oplus) \rightarrow$



$\frac{\partial}{\partial x_t}$   $\xrightarrow{\text{입력}} \text{신경망} \xrightarrow{\text{출력}} \text{클래스 } y \Rightarrow \text{일반적인 확장} \xrightarrow{\text{전부}} \text{확산 모델}$

시각 티에시의  
노이즈 이미지

$$\nabla P_\phi(y|x)$$

이를 위한 고장:

1. 확산 모델은 점수  $\nabla_{x_t} \log P(x_t)$ 을 예측하는 신경망을 구현할 수 있다.

분류기 가이던스

2. 전부 확산 모델은 전부 확률 점수  $\nabla_{x_t} \log P(x_t|y)$ 을 예측하는 신경망을 구현할 수 있다.

우선:

비아웃 차이

$$\nabla_{x_t} \log P(x_t|y) = \nabla_{x_t} \log \left( \frac{P(x_t) P(y|x_t)}{P(y)} \right)$$

전부 점수

$$= \nabla_{x_t} (\log p(x_t)) + \nabla_{x_t} \log P(y|x_t) - \nabla_{x_t} \log P(y)$$


점수  
↑ 계산

점수 예측 신경망

$S_\theta(x_t, t)$

분류기 고기 가능성의 기울기

↑ 계산  
분류기 신경망




증명  $\nabla_{x_t} \log P(x_t|y)$   $\Rightarrow$  분류기 기여로 가정

$$= \nabla_{x_t} \log p(x_t) + \nabla_{x_t} \log P(y|x_t)$$

시각화

$\approx S_\theta(x_t, t) + \nabla_{x_t} \log P_\phi(y|x_t)$

점수 추정 신경망  
 $\nabla_{x_t} \log P_\phi(y|x_t)$



마지막

## 10.4 분류기 없는 가이던스 (classifier-free guidance)

분류기 없는 가이던스 공식!

$$\nabla_{x_t} \log p(x_t|y) \rightarrow \text{조건부 정수}$$

$$= \nabla_{x_t} \log p(x_t) + r \nabla_{x_t} \log p(y|x_t) \rightarrow \text{분류기 가이던스}$$

$$= \nabla_{x_t} \log p(x_t) + r \left( \underbrace{\nabla_{x_t} \log p(x_t|y)}_0 + \underbrace{\nabla_{x_t} \log p(y) - \nabla_{x_t} \log p(x_t)}_{\text{베이즈 정리}} \right)$$

조건부 정수

↑  
주정

$$S_\theta(x_t, t)$$


조건 없는 정수

↑  
주정

$$S_\phi(x_t, t, y)$$

이는 뭘?

$$\nabla_{x_t} \log p(x_t) \text{와 } \nabla_{x_t} \log p(x_t|y) \text{는 } r \text{의 } \frac{1}{r} \text{ 배수인 } \frac{1}{r} \text{ 등}$$



구현은?

하나의 NN망으로 구현? ↗  
→ 조건 없는 정수 주정;  $S_\phi(x_t, t, \emptyset)$   
→ 조건부 정수 주정;  $S_\theta(x_t, t, y)$

즉! 분류기 없는 가이던스 공식은?

$$\nabla_{x_t} \log p(x_t|y) \approx S_\theta(x_t, t, y) + r(S_\phi(x_t, t, y) - S_\theta(x_t, t, \emptyset))$$

